Nume și Prenume: Deac Lorena-Daniela
Grupa: 30133
Anul: 3 , seria B

Documentație proiect SBC

Analiza și modelarea degradării unui sistem de propulsie naval bazat pe turbine cu gaz

Facultatea de Automatică și Calculatoare

UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

Data: February 7, 2026

Contents

1. Introducere *2*
1.1 Context general 2
1.2 Obiectiv 3
1.3 Specificatii 4

2. Cunoasterea si analiza setului de date *5*
2.1 Mediul de implementare și analiza inițială a datelor 5
2.2 Analiza vizuală exploratorie a datelor 6
2.3 Analiza avansată a corelațiilor dintre caracteristici 7
2.4 Analiza vizuală avansată a parametrilor cheie 9
2.5 Evaluarea calității setului de date 10

3. Pre-procesarea setului de date *11*
3.1 Tratarea valorilor lipsă și standardizarea datelor 11
3.2 Reducerea dimensionalității folosind analiza componentelor principale 12
3.3 Generarea de caracteristici derivate (Feature Engineering) . . . 13
3.4 Detectarea și tratarea valorilor aberante 14
3.5 Reproductibilitatea procesului de pre-procesare 15

4. Modelarea sistemului *15*
4.1 Formularea problemei și metodologia de modelare 15
4.2 Tehnici de modelare utilizate 16
4.3 Procedura de antrenare și implementare 17
4.4 Evaluarea performanței modelelor 17
4.5 Analiza grafică a predicțiilor 18
4.6 Selectarea modelului optim 19
4.7 Reproductibilitatea și utilizarea aplicației 19

5. Concluzii *20*
5.1 Rezultate obținute 20
5.2 Direcții de dezvoltare 21

6. Bibliografie *22*

1. Introducere

1.1 Context general

Evoluția sistemelor moderne de propulsie navală a condus la creșterea semnificativă a complexității acestora, atât din punct de vedere mecanic, cât și din perspectiva sistemelor de control și monitorizare. Turbinele și compresoarele cu gaz reprezintă componente critice ale acestor sisteme, iar funcționarea lor în regimuri variabile de sarcină conduce, în timp, la procese inevitabile de uzură și degradare, care pot afecta performanța globală și siguranța exploatării.

Tema acestui proiect a fost aleasă pornind de la necesitatea practică de a monitoriza și evalua starea de sănătate a sistemelor de propulsie navală, în vederea prevenirii defecțiunilor majore și a optimizării costurilor de exploatare. În mediul naval, opririle neplanificate sau avariile pot avea consecințe economice și operaționale semnificative, motiv pentru care strategiile clasice de mentenanță corectivă sau preventivă, bazate pe intervale fixe de timp, devin insuficiente.

Mentenanța predictivă reprezintă o abordare modernă, bazată pe analiza datelor operaționale și pe utilizarea algoritmilor de învățare automată, care permite estimarea stării viitoare a componentelor și intervenția înainte de apariția defectelor critice. Această paradigmă reduce timpul de nefuncționare al echipamentelor, optimizează utilizarea resurselor și contribuie la creșterea fiabilității sistemelor complexe.

Din punct de vedere teoretic, utilizarea tehnicilor de Machine Learning în mentenanța predictivă se bazează pe capacitatea acestora de a identifica relații neliniare între parametrii operaționali și indicatorii de degradare, relații dificil de modelat prin metode analitice clasice. Algoritmi precum Random Forest, Gradient Boosting sau Support Vector Regression sunt capabili să surprindă aceste dependențe complexe și să ofere predicții robuste chiar și în prezența zgomotului din date.

De asemenea , cunoașterea și analiza setului de date urmăresc înțelegerea parametrilor operaționali ai sistemului de propulsie naval și identificarea relațiilor relevante dintre aceștia , in timp ce pre-procesarea datelor are rolul de a îmbunătăți calitatea informației prin reducerea dimensionalității și generarea de caracteristici derivate, necesare surprinderii dinamicii sistemului.

O alta parte importanta o reprezinta modelarea sistemului: realizată prin

formularea unei probleme de regresie, având ca obiectiv estimarea coeficienților de degradare ai componentelor critice.

Tehnicile utilizate detin , de asemenea , un rol crucial , datorita faptului ca includ algoritmi de Machine Learning pentru regresie și metode de detectare a anomaliilor, contribuind la dezvoltarea unei soluții orientate spre mentenanță predictivă.

Astfel, această temă a fost aleasă pentru a îmbina conceptele teoretice studiate în cadrul disciplinei *Sisteme Bazate pe Cunoaștere* cu o aplicație practică relevantă, orientată spre analiza datelor reale, suport decizional și mentenanță predictivă în sisteme industriale critice.

1.2 Obiectiv

Întrebarea principală care a stat la baza realizării acestui proiect este următoarea:

Cum pot fi utilizate datele operaționale ale unui sistem de propulsie naval pentru a evalua starea de sănătate a componentelor critice și pentru a sprijini deciziile de mentenanță predictivă?

Pentru a răspunde acestei întrebări, proiectul a fost conceput cu scopul de a obține o soluție analitică și predictivă bazată pe date, care să permită evaluarea stării unui sistem de propulsie naval și sprijinirea procesului decizional în activitățile de mentenanță.

În acest sens, obiectivele urmărite au fost:

- obținerea unei înțelegeri detaliate a comportamentului sistemului de propulsie naval prin analiza parametrilor operaționali disponibili;
- identificarea relațiilor relevante dintre variabilele măsurate și starea de degradare a componentelor critice;
- dezvoltarea unor modele predictive capabile să estimeze coeficienții de degradare ai compresorului și turbinei cu gaz;
- evaluarea performanței modelelor utilizate și selectarea celor mai potrivite pentru scopul mentenanței predictive;
- detectarea regimurilor de funcționare anormale care pot indica apariția unor defecțiuni sau condiții nesigure;

- demonstrarea aplicabilității tehnicilor de Machine Learning în analiza și monitorizarea sistemelor industriale complexe.

1.3 Specificatii

Lucrarea urmărește realizarea unei aplicații software orientate spre analiza și modelarea unui sistem de propulsie naval, pe baza unui set de date numerice reale. Specificațiile proiectului sunt structurate după cum urmează:

- **Funcționalitate:** aplicația trebuie să permită încărcarea și analiza unui set de date ce conține parametri operaționali și coeficienți de degradare ai componentelor sistemului de propulsie;
- **Analiza datelor:** sistemul trebuie să ofere suport pentru analiză exploratorie, vizualizare grafică și identificarea corelațiilor dintre variabile;
- **Pre-procesare:** datele trebuie standardizate, completate în cazul valorilor lipsă și transformate prin tehnici de reducere a dimensionalității și *feature engineering*;
- **Modelare:** aplicația trebuie să implementeze modele de Machine Learning pentru regresie, capabile să estimeze coeficienții de degradare ai compresorului și turbinei;
- **Evaluarea performanței:** modelele trebuie evaluate utilizând metrici cantitative precum RMSE și coeficientul de determinare R^2;
- **Detectarea anomaliilor:** sistemul trebuie să includă un mecanism automat de identificare a comportamentelor anormale în datele operaționale;
- **Interfață:** aplicația este realizată sub forma unui script Python, cu rezultate prezentate prin grafice și rapoarte textuale, fără interfață grafică dedicată;
- **Fiabilitate și calitate:** soluția trebuie să producă rezultate reproductibile și să fie ușor de extins pentru alte seturi de date similare;
- **Limitări:** aplicația este dependentă de calitatea datelor disponibile și nu realizează predicții în timp real, fiind destinată analizei offline.

2. Cunoasterea si analiza setului de date

Acest capitol are rolul de a analiza și înțelege setul de date pus la dispoziție, constituind baza pentru etapele ulterioare de pre-procesare și modelare. Analiza este realizată într-o manieră exploratorie, folosind atât statistici descriptive, cât și reprezentări grafice și analize de corelație, conform bunelor practici din literatura de specialitate privind analiza datelor operaționale industriale.

Prin această etapă se urmărește obținerea unei înțelegeri clare asupra structurii informațiilor disponibile, a comportamentului parametrilor măsurați și a nivelului de calitate al datelor, aspecte esențiale pentru construirea unor modele predictive robuste și interpretabile.

2.1 Mediul de implementare și analiza inițială a datelor

Aplicația a fost dezvoltată în limbajul Python, utilizând un mediu de execuție standard dedicat analizei datelor și tehnicilor de Machine Learning. Limbajul Python a fost ales datorită flexibilității sale, a suportului extins din partea comunității și a disponibilității unui ecosistem matur de biblioteci pentru analiza datelor industriale.

Principalele biblioteci utilizate sunt `NumPy` și `Pandas` pentru manipularea și prelucrarea setului de date, respectiv `Matplotlib` și `Seaborn` pentru realizarea reprezentărilor grafice. Aceste instrumente permit o analiză eficientă a volumelor mari de date și facilitarea interpretării vizuale a rezultatelor.

În această etapă a fost realizată analiza inițială a setului de date, care include:

- încărcarea setului de date și curățarea denumirilor de coloane, pentru asigurarea consistenței;
- inspectarea dimensiunii și structurii datelor disponibile;
- verificarea tipurilor de date asociate fiecărei variabile;
- identificarea eventualelor valori lipsă;
- calcularea statisticilor descriptive de bază.

Analiza inițială a setului de date a fost implementată prin intermediul funcției `functie1_analiza`. Această funcție are rolul de a:

- determina dimensiunea setului de date;

- identifica tipurile de date asociate fiecărei variabile;
- verifica existența valorilor lipsă;
- calcula statisticile descriptive de bază.

Această analiză inițială are rolul de a valida setul de date din punct de vedere al calității și coerenței informațiilor. Rezultatele obținute indică faptul că datele sunt bine structurate și pot fi utilizate în siguranță în etapele următoare de analiză vizuală, pre-procesare și modelare predictivă.

2.2 Analiza vizuală exploratorie a datelor

Analiza vizuală reprezintă un pas esențial în procesul de cunoaștere a datelor, deoarece permite identificarea rapidă a distribuțiilor variabilelor și a eventualelor relații dintre acestea. În cadrul acestui proiect, analiza vizuală de bază a fost realizată prin intermediul funcției `functie2_vizualizareBaza`.

Această funcție generează:

- histograme pentru principalii parametri numerici, utilizate pentru analizarea distribuțiilor și a domeniilor de funcționare;
- matricea de corelație Pearson, reprezentată sub formă de hartă de căldură, pentru evidențierea relațiilor liniare dintre variabile.

Histogramele permit observarea comportamentului statistic al parametrilor operaționali, evidențiind eventuale asimetrii sau valori extreme. Matricea de corelație oferă o primă imagine asupra gradului de dependență dintre variabile, indicând ce parametri pot avea o influență directă asupra coeficienților de degradare.

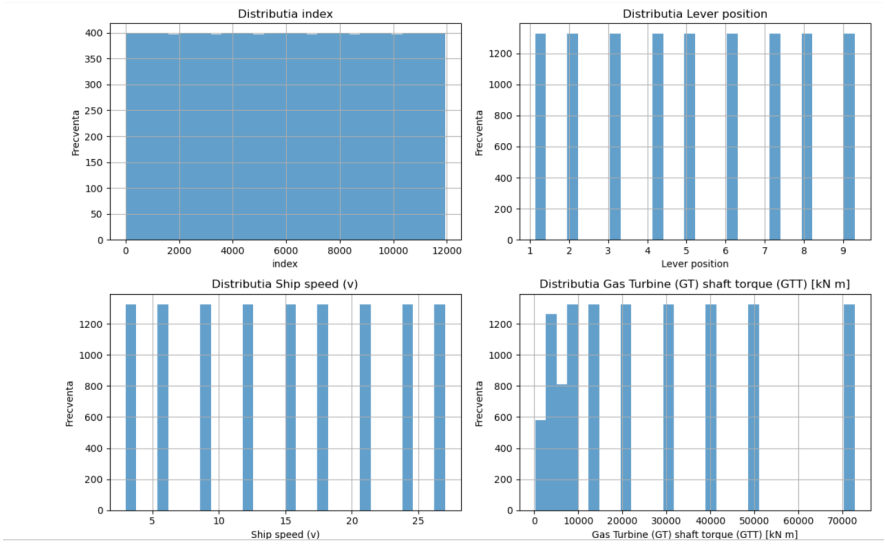

Figure 1: 2.2.1 Distribuția parametrilor operaționali

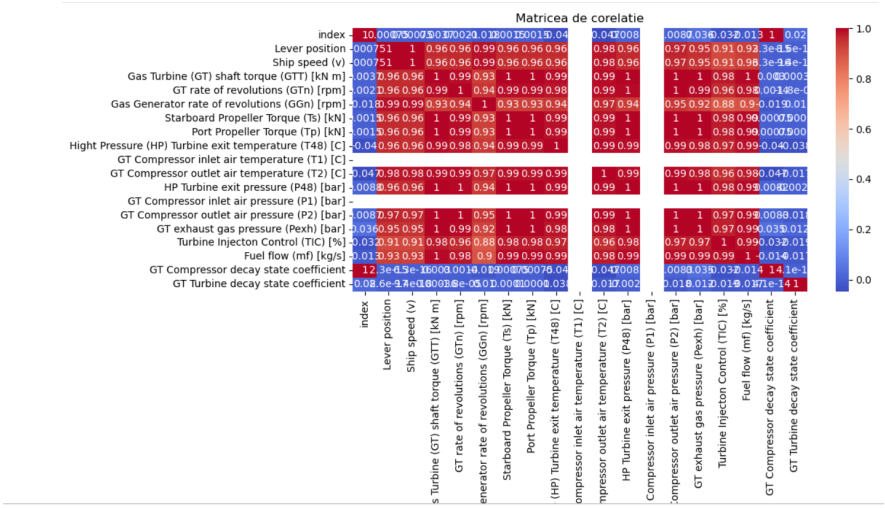

Figure 2: 2.2.2 Matricea de corelație Pearson

2.3 Analiza avansată a corelațiilor dintre caracteristici

Pentru o analiză mai aprofundată a relațiilor dintre variabile, a fost implementată funcția `functie3_corelatieAvansata`. Aceasta are rolul de a iden-

tifica automat corelațiile puternice și moderate dintre caracteristicile setului de date, pe baza valorii coeficientului de corelație Pearson.

Prin această abordare sunt evidențiate:

- corelațiile puternice, care pot indica relații fizice directe sau redundanță informațională;
- corelațiile moderate, care sugerează influențe indirecte sau dependente de regimul de funcționare al sistemului.

Rezultatele obținute confirmă existența unor relații semnificative între anumiți parametri operaționali și coeficienții de degradare ai compresorului și turbinei. Aceste observații sunt în concordanță cu rezultatele raportate în literatura de specialitate privind analiza sistemelor de propulsie cu turbină cu gaz.

Identificarea acestor corelații a constituit un criteriu important pentru selecția caracteristicilor utilizate în etapele ulterioare de pre-procesare și modelare predictivă.

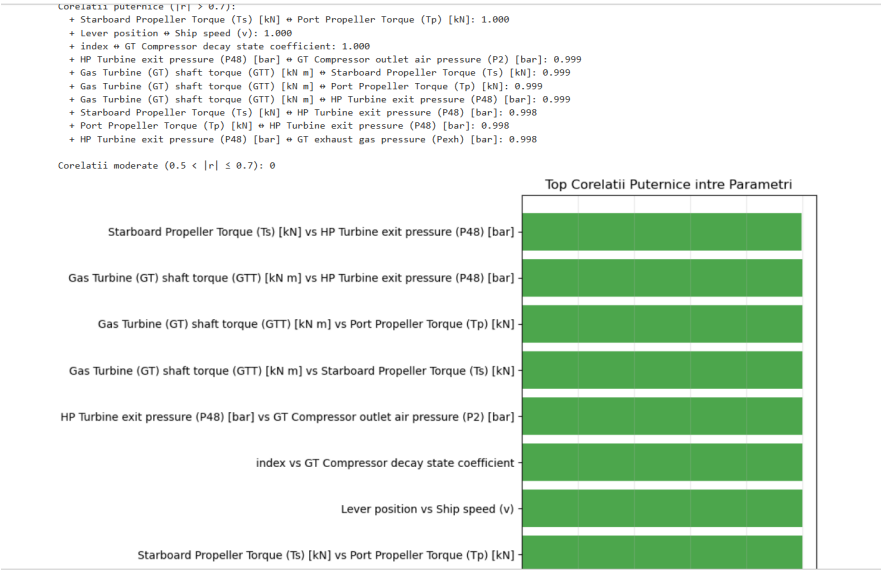

Figure 3: 2.3 Corelații relevante identificate între parametrii sistemului

Coeficientul de corelație Pearson utilizat în cadrul acestei analize este definit prin relația:

$$\rho_{X,Y} = \frac{\sum_{i=1}^{N}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{N}(X_i - \overline{X})^2 \sum_{i=1}^{N}(Y_i - \overline{Y})^2}}$$

unde X și Y reprezintă două variabile aleatorii, $\overline{X}$ și $\overline{Y}$ sunt mediile acestora, iar N este numărul de observații.

2.4 Analiza vizuală avansată a parametrilor cheie

După analiza vizuală de bază și studiul corelațiilor globale dintre variabile, a fost realizată o analiză vizuală avansată a unor parametri operaționali considerați cheie pentru funcționarea sistemului de propulsie naval. Această etapă are rolul de a evidenția comportamentul detaliat al variabilelor relevante și relațiile punctuale dintre acestea.

Analiza este implementată în aplicație prin intermediul funcției `functie7_analizaAvansata`, care generează reprezentări grafice dedicate pentru parametrii selectați, în funcție de importanța acestora în procesul de degradare a componentelor critice.

Această analiză include:

- reprezentări grafice de tip scatter pentru investigarea relațiilor dintre parametri operaționali și coeficienții de degradare;
- analiza variației parametrilor cheie în funcție de regimul de funcționare al sistemului;
- evidențierea zonelor de operare normale și a posibilelor comportamente atipice;
- suport vizual pentru selecția caracteristicilor utilizate în etapele ulterioare de pre-procesare și modelare.

Astfel de analize sunt frecvent utilizate în literatura de specialitate pentru înțelegerea profundă a datelor operaționale și pentru fundamentarea deciziilor privind reducerea dimensionalității și alegerea variabilelor relevante.

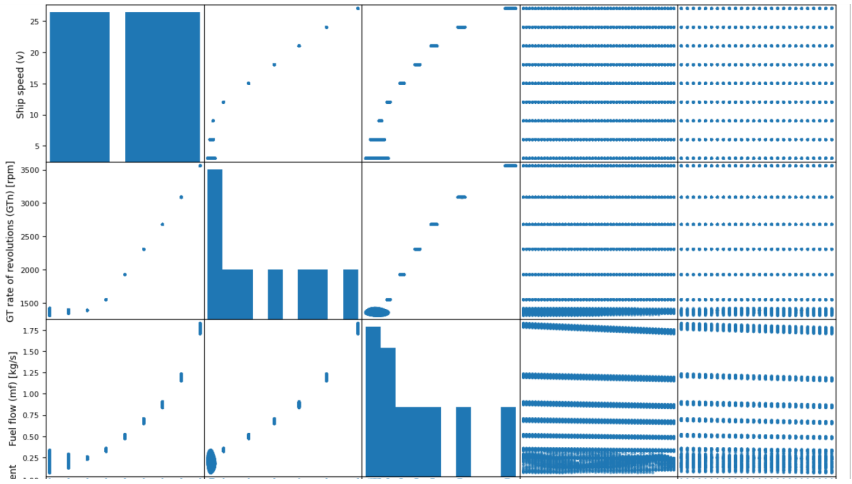

Figure 4: 2.4.1 Analiza vizuală a unui parametru operațional cheie

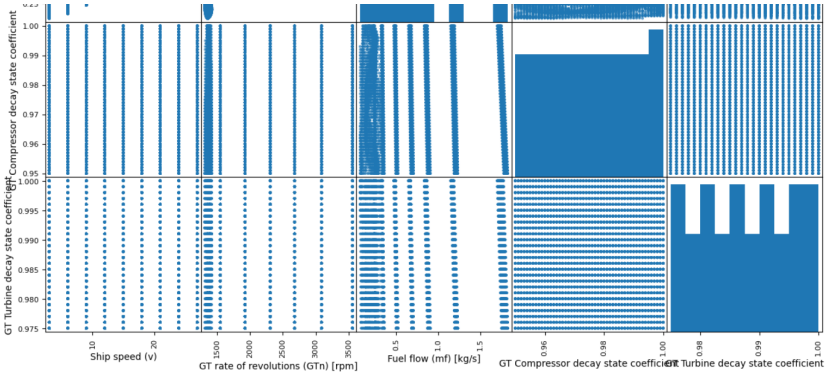

Figure 5: 2.4.2 Analiza vizuala a unui parametru opertaional cheie-continuare figura

Rezultatele obținute în urma acestei etape au contribuit la o înțelegere mai detaliată a comportamentului sistemului și au stat la baza selecției caracteristicilor utilizate în capitolele următoare.

2.5 Evaluarea calității setului de date

Pe baza analizelor realizate în cadrul acestui capitol, a fost efectuată o evaluare generală a calității setului de date. Lipsa valorilor lipsă semnificative,

consistența statistică a parametrilor și relațiile identificate între variabile indică faptul că datele sunt adecvate pentru aplicarea tehnicilor de pre-procesare, reducere a dimensionalității și modelare predictivă.

Această etapă validează utilizarea setului de date în scopuri de mentenanță predictivă și oferă un fundament solid pentru etapele următoare ale proiectului.

3. Pre-procesarea setului de date

Pre-procesarea setului de date reprezintă o etapă esențială în cadrul oricărui proiect de analiză și modelare bazată pe date, având rolul de a îmbunătăți calitatea informațiilor utilizate și de a facilita aplicarea algoritmilor de Machine Learning. În cazul sistemelor industriale complexe, precum sistemele de propulsie navală, această etapă este cu atât mai importantă, deoarece datele operaționale pot conține redundanță, corelații puternice sau variații nedorite.

În cadrul acestui proiect, pre-procesarea a inclus metode de standardizare, reducere a dimensionalității, generare de caracteristici derivate și tratarea valorilor lipsă, având ca scop creșterea performanței și interpretabilității modelelor predictive.

3.1 Tratarea valorilor lipsă și standardizarea datelor

Înainte de aplicarea metodelor avansate de analiză, a fost necesară verificarea și tratarea valorilor lipsă din setul de date. Deși setul de date utilizat prezintă un nivel ridicat de completitudine, au fost aplicate metode de imputare pentru a asigura consistența numerică necesară algoritmilor de Machine Learning.

Valorile lipsă au fost tratate prin înlocuirea acestora cu valori reprezentative (media sau mediana), în funcție de contextul analizei. Această abordare este frecvent utilizată în literatura de specialitate pentru a preveni distorsionarea distribuțiilor și pierderea informației.

Ulterior, datele au fost standardizate pentru a aduce toate variabilele pe o scară comună. Standardizarea este esențială în special pentru algoritmi sensibili la magnitudinea caracteristicilor, precum PCA sau Support Vector Regression.

Standardizarea variabilelor a fost realizată folosind transformarea de tip *z-score*, definită prin relația:

$$X_{std} = \frac{X - \mu}{\sigma}$$

unde μ reprezintă media variabilei, iar σ abaterea standard.

3.2 Reducerea dimensionalității folosind analiza componentelor principale

Pentru a analiza structura internă a setului de date și pentru a reduce redundanța informațională, a fost aplicată analiza componentelor principale (Principal Component Analysis – PCA). Această metodă permite transformarea variabilelor originale într-un set de componente ortogonale, care captează maximum de variație din date.

Aplicarea PCA a fost realizată în cadrul funcției `functie4_reduceDimensiune`. Aceasta calculează contribuția fiecărei componente principale și varianta explicată cumulativ, oferind suport pentru alegerea unui număr optim de componente.

Rezultatele obținute indică faptul că un număr redus de componente principale explică un procent semnificativ din variabilitatea totală a datelor, confirmând existența unor corelații puternice între parametrii operaționali.

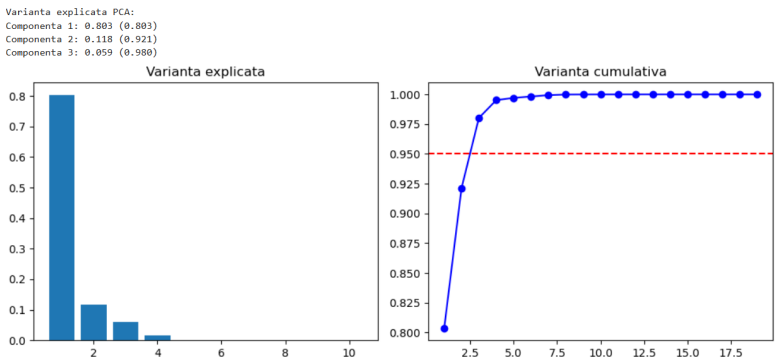

Figure 6: 3.2 Varianta explicată și varianta cumulativă pentru componentele principale

Reducerea dimensionalității contribuie la scăderea complexității computaționale și la îmbunătățirea interpretabilității modelelor predictive utilizate ulterior.

Analiza componentelor principale (PCA) se bazează pe diagonalizarea matricei de covarianță:

$$\Sigma = \frac{1}{N-1} X^T X$$

unde X este matricea datelor standardizate. Componentele principale sunt vectorii proprii ai matricei Σ, iar valorile proprii asociate indică varianta explicată de fiecare componentă.

Procentul de variație explicată de componenta k este:

$$Var_k = \frac{\lambda_k}{\sum_{i=1}^{p} \lambda_i}$$

unde λ_k este valoarea proprie corespunzătoare componentei k.

3.3 Generarea de caracteristici derivate (Feature Engineering)

Pentru a surprinde mai bine dinamica sistemului de propulsie naval, a fost aplicată o etapă de *feature engineering*, implementată prin intermediul funcției `functie5_features`. Această etapă urmărește crearea unor variabile suplimentare care să reflecte comportamentul temporal și operațional al sistemului.

Au fost generate următoarele tipuri de caracteristici:

- variația temporală a parametrilor, prin calculul diferențelor dintre eșantioane consecutive;
- medii și deviații standard pe ferestre glisante, pentru captarea tendințelor locale;
- indicatori de eficiență operațională, obținuți din relații între parametri relevanți.

Aceste caracteristici permit captarea comportamentului dinamic al sistemului și oferă informații suplimentare care nu sunt evidente în datele brute.

```
Feature-uri initiale: 19
Feature-uri dupa inginerie: 77
Feature-urile noi create sunt:58
```

Figure 7: 3.3 Exemplu de caracteristici derivate obținute prin feature engineering

Rezultatele obținute au condus la o creștere semnificativă a numărului de caracteristici disponibile, îmbunătățind capacitatea modelelor de a estima starea de degradare a componentelor.

3.4 Detectarea și tratarea valorilor aberante

În cadrul procesului de pre-procesare a fost realizată și o analiză a valorilor aberante, utilizând o abordare bazată pe algoritmi de învățare automată. Pentru acest scop a fost utilizat algoritmul *Isolation Forest*, implementat în funcția `functie10_detectare_anomalii`.

Această metodă permite identificarea observațiilor care se abat semnificativ de la comportamentul normal al sistemului, fără a necesita ipoteze explicite asupra distribuției datelor.

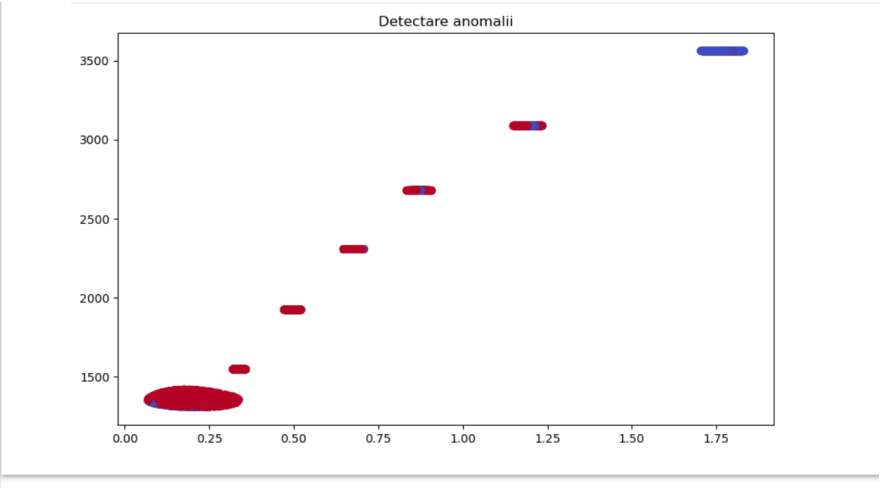

Figure 8: 3.4 Detectarea anomaliilor în spațiul parametrilor operaționali

Identificarea valorilor aberante este esențială pentru evitarea influenței

negative asupra procesului de modelare și pentru sprijinirea deciziilor de mentenanță predictivă.

Algoritmul Isolation Forest se bazează pe ideea izolării observațiilor prin partiționări aleatorii. Scorul de anomalie este definit ca:

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}}$$

unde $E(h(x))$ este lungimea medie a drumului de izolare pentru observația x, iar $c(n)$ este o constantă de normalizare dependentă de dimensiunea eșantionului.

3.5 Reproductibilitatea procesului de pre-procesare

Pentru a asigura reproductibilitatea proiectului, toate etapele de pre-procesare au fost implementate sub formă de funcții modulare, aplicate într-o ordine clar definită. Această abordare permite refacerea completă a procesului de analiză și modelare, pornind de la setul de date inițial.

Informațiile prezentate în acest capitol oferă suficiente detalii pentru ca un utilizator familiarizat cu analiza datelor să poată reproduce rezultatele obținute și să extindă proiectul către alte seturi de date sau scenarii operaționale similare.

4. Modelarea sistemului

Acest capitol este dedicat dezvoltării și evaluării modelelor predictive utilizate pentru estimarea stării de degradare a componentelor critice ale sistemului de propulsie naval. Pe baza setului de date pre-procesat, problema este formulată ca una de regresie, având ca scop predicția coeficienților de degradare ai compresorului și turbinei cu gaz.

Modelarea este realizată folosind algoritmi de Machine Learning consacrați, capabili să surprindă relații complexe și neliniare între parametrii operaționali și indicatorii de stare ai sistemului.

4.1 Formularea problemei și metodologia de modelare

Problema abordată în cadrul acestui proiect constă în estimarea valorilor coeficienților de degradare ai compresorului și turbinei, pe baza parametrilor operaționali măsurați în timpul funcționării sistemului naval.

Din punct de vedere metodologic, problema este formulată ca o problemă de regresie supravegheată, în care:

- datele de intrare sunt reprezentate de parametrii operaționali și caracteristicile derivate;
- ieșirile sunt coeficienții de degradare ai componentelor critice;
- modelele sunt antrenate pe date istorice etichetate.

Această abordare este larg utilizată în mentenanța predictivă, fiind susținută de literatura de specialitate privind analiza bazată pe date a sistemelor industriale complexe.

Problema de modelare este formulată ca o problemă de regresie supravegheată:

$$y = f(X) + \varepsilon$$

unde $X \in R^{n \times p}$ reprezintă matricea caracteristicilor de intrare, y este coeficientul de degradare estimat, iar ε reprezintă termenul de eroare.

4.2 Tehnici de modelare utilizate

Pentru rezolvarea problemei au fost aplicate mai multe tehnici de Machine Learning, alese în funcție de capacitatea lor de a modela relații neliniare și de robustețea în prezența zgomotului din date.

Modelele utilizate în cadrul proiectului sunt:

- **Random Forest Regressor** – model de tip ensemble, bazat pe arbori de decizie, capabil să reducă supraînvățarea și să ofere estimări stabile;
- **Gradient Boosting Regressor** – metodă iterativă care construiește modele succesive pentru corectarea erorilor anterioare;
- **Support Vector Regression (SVR)** – algoritm eficient pentru regresii neliniare, sensibil la scalarea datelor.

Toate aceste modele sunt implementate și gestionate în cadrul funcției `functie8_modelarePredictiva`.

4.3 Procedura de antrenare și implementare

Procesul de modelare a fost implementat într-o manieră modulară și reproductibilă, respectând următorii pași:

- separarea setului de date în subseturi de antrenare și testare;
- standardizarea caracteristicilor de intrare, acolo unde este necesar;
- antrenarea modelelor pe datele de antrenare;
- generarea predicțiilor pentru datele de test;
- salvarea și compararea rezultatelor obținute.

Aplicația a fost dezvoltată în Python, folosind biblioteca `Scikit-learn`, iar execuția se realizează într-un mediu standard de analiză a datelor. Structura modulară a funcțiilor permite refacerea completă a procesului de modelare și extinderea acestuia cu noi algoritmi sau seturi de date.

4.4 Evaluarea performanței modelelor

Evaluarea performanței modelelor predictive este realizată utilizând metrici standard pentru problemele de regresie, care permit compararea obiectivă a rezultatelor obținute.

Metricile utilizate sunt:

- **RMSE (Root Mean Squared Error)** – măsoară eroarea medie de predicție;
- **Coeficientul de determinare** R^2 – indică proporția din variația datelor explicată de model.

Aceste metrici sunt calculate separat pentru predicția coeficientului de degradare al compresorului și al turbinei.

```
Shape X: (11934, 75)
Shape y_comp: (11934,)
Shape y_turb: (11934,)

=== MODEL: Random Forest ===
Compresor → RMSE=0.0000 | R²=1.0000
Turbina →  RMSE=0.0000 | R²=1.0000

=== MODEL: Gradient Boosting ===
Compresor → RMSE=0.0001 | R²=1.0000
Turbina →  RMSE=0.0000 | R²=1.0000

=== MODEL: SVR ===
Compresor → RMSE=0.0147 | R²=-0.0003
Turbina →  RMSE=0.0075 | R²=-0.0003

============================
   REZULTATE COMPARATIVE
============================
                   Compresor_RMSE  Compresor_R2  Turbina_RMSE  Turbina_R2
Random Forest            0.000045      0.999990  2.129684e-15    1.000000
Gradient Boosting        0.000056      0.999985  3.156237e-05    0.999983
SVR                      0.014664     -0.000285  7.549717e-03   -0.000255

>> Cel mai bun model pentru compresor este: Random Forest
```

Figure 9: 4.4 Compararea performanțelor modelelor predictive

Analiza rezultatelor evidențiază diferențe semnificative între modelele utilizate, atât din punct de vedere al preciziei, cât și al stabilității predicțiilor.

Eroarea RMSE este definită prin relația:

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}$$

Coeficientul de determinare este definit ca:

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \overline{y})^2}$$

4.5 Analiza grafică a predicțiilor

Pentru o evaluare vizuală a performanței, au fost analizate graficele de tip *valori reale versus valori prezise*, precum și distribuția reziduurilor. Aceste reprezentări grafice permit identificarea eventualelor tendințe sistematice sau erori de modelare.

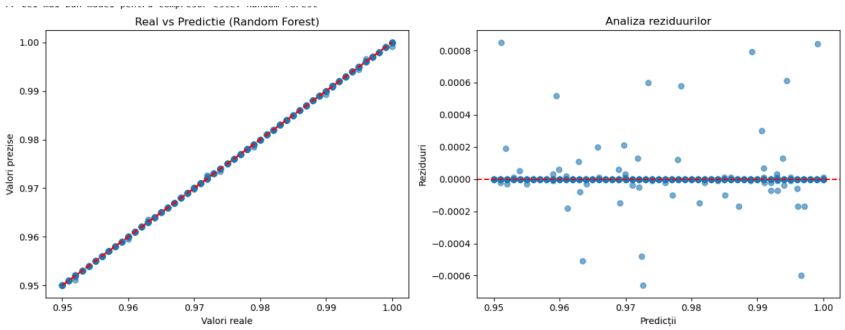

Figure 10: 4.5 Compararea valorilor reale și a predicțiilor modelului selectat si analiza reziduurilor pentru modelul optim

Rezultatele obținute indică o bună capacitate de generalizare a modelului ales, fără erori sistematice evidente.

4.6 Selectarea modelului optim

Pe baza valorilor obținute pentru metricile de evaluare și a analizelor grafice, a fost selectat modelul care oferă cel mai bun compromis între acuratețe și stabilitate. Alegerea finală este realizată în mod automat în cadrul funcției de modelare, pe baza coeficientului R^2.

Modelul selectat este utilizat ulterior pentru suport decizional în mentenanța predictivă și pentru analiza comportamentului viitor al sistemului.

4.7 Reproductibilitatea și utilizarea aplicației

Pentru a permite refacerea și extinderea lucrării, întregul proces de modelare este implementat sub formă de funcții independente, care pot fi apelate succesiv. Parametrii principali ai modelelor sunt configurabili, iar rezultatele sunt afișate atât numeric, cât și grafic.

Această structură permite utilizarea aplicației în contexte similare, precum analiza altor sisteme industriale sau extinderea către monitorizare în timp real.

5. Concluzii

Acest capitol sintetizează rezultatele obținute în cadrul proiectului și evidențiază contribuțiile realizate în domeniul analizei și modelării sistemelor de propulsie navală bazate pe date. De asemenea, sunt prezentate direcțiile posibile de dezvoltare, având în vedere limitările soluției propuse și potențialul de extindere al acesteia.

5.1 Rezultate obținute

Obiectivul principal al proiectului a fost utilizarea datelor operaționale ale unui sistem de propulsie naval pentru evaluarea stării de sănătate a componentelor critice și sprijinirea deciziilor de mentenanță predictivă. Analiza realizată demonstrează faptul că tehnicile moderne de Machine Learning pot fi aplicate cu succes în acest context, oferind rezultate relevante și interpretabile.

Principalele rezultate obținute pot fi sintetizate astfel:

- a fost realizată o analiză exploratorie detaliată a setului de date, care a permis înțelegerea structurii acestuia, a distribuțiilor parametrilor operaționali și a relațiilor dintre variabile;
- au fost identificate corelații semnificative între parametrii operaționali ai sistemului și coeficienții de degradare ai compresorului și turbinei, confirmând observații raportate în literatura de specialitate;
- a fost aplicată analiza componentelor principale (PCA), demonstrând existența unei redundanțe informaționale și permițând reducerea dimensionalității fără pierderi semnificative de informație;
- prin etapa de *feature engineering* au fost generate caracteristici derivate care surprind dinamica temporală și comportamentul operațional al sistemului, îmbunătățind capacitatea de predicție a modelelor;
- au fost dezvoltate și comparate mai multe modele de regresie (Random Forest, Gradient Boosting și Support Vector Regression), evidențiindu-se diferențe clare de performanță între acestea;
- modelul selectat a demonstrat o capacitate bună de generalizare, obținând valori ridicate ale coeficientului de determinare R^2 și erori reduse de tip RMSE;

- a fost implementată o metodă de detectare a anomaliilor bazată pe algoritmul Isolation Forest, care permite identificarea regimurilor de funcționare neobișnuite și a observațiilor potențial problematice.

Comparativ cu abordările clasice de mentenanță preventivă, soluția propusă oferă un avantaj semnificativ prin capacitatea de a anticipa degradarea componentelor înainte de apariția defectelor critice. În raport cu studiile existente din domeniul mentenanței predictive bazate pe date, rezultatele obținute sunt în concordanță cu acestea, confirmând eficiența algoritmilor de tip ensemble și a metodelor de analiză a caracteristicilor derivate.

Contribuțiile personale ale acestui proiect includ:

- integrarea completă a etapelor de analiză, pre-procesare, modelare și evaluare într-un flux coerent și reproductibil;
- adaptarea tehnicilor de Machine Learning la un set de date real din domeniul naval;
- analiza comparativă a mai multor modele predictive și selectarea automată a modelului optim;
- implementarea unei soluții de detectare a anomaliilor cu potențial de utilizare în mentenanța predictivă.

5.2 Direcții de dezvoltare

Deși rezultatele obținute sunt promițătoare, există numeroase direcții prin care proiectul poate fi extins și îmbunătățit. Printre acestea se numără:

- integrarea unor modele avansate de tip rețele neuronale profunde, care pot surprinde relații neliniare mai complexe;
- extinderea analizei către date provenite de la mai multe nave sau din regimuri de funcționare diferite, pentru creșterea robusteții modelelor;
- implementarea unui sistem de monitorizare în timp real, capabil să furnizeze alerte automate în cazul apariției anomaliilor;
- utilizarea tehnicilor de selecție automată a caracteristicilor și optimizare a hiperparametrilor;

- integrarea soluției într-o platformă software de suport decizional pentru mentenanța predictivă.

În concluzie, proiectul demonstrează aplicabilitatea practică a tehnicilor de Machine Learning în analiza sistemelor industriale complexe și oferă o bază solidă pentru dezvoltări viitoare în domeniul mentenanței predictive a sistemelor de propulsie navală.

6. Bibliografie

Bibliografia utilizată în cadrul acestei lucrări reunește articole științifice și materiale de specialitate relevante pentru domeniul mentenanței predictive, al analizei datelor și al utilizării tehnicilor de Machine Learning în sisteme industriale complexe. Sursele selectate au fost utilizate atât pentru fundamentarea teoretică a conceptelor abordate, cât și pentru definirea metodologiilor de analiză, pre-procesare și modelare a datelor.

Lucrările internaționale consultate oferă o perspectivă actuală asupra algoritmilor de învățare automată, a metodelor de evaluare și a aplicațiilor acestora în monitorizarea și diagnosticarea echipamentelor critice. În paralel, au fost studiate articole publicate în limba română, care tratează aspecte legate de mentenanța predictivă, analiza exploratorie a datelor și preprocesarea informațiilor industriale, contribuind la înțelegerea contextului aplicativ specific.

Documentația tehnică și ghidurile de stil IEEE au fost utilizate pentru asigurarea unei citări corecte și unitare a surselor bibliografice, precum și pentru redactarea lucrării conform standardelor academice. Astfel, bibliografia reflectă atât baza teoretică necesară dezvoltării proiectului, cât și preocuparea pentru respectarea bunelor practici în redactarea lucrărilor științifice.

Surse bibliografice:

1. M. Popescu și A. Ionescu, Mentenanța predictivă bazată pe analiza datelor în sisteme industriale complexe," *Revista de Automatică și Informatică Aplicată*, vol. 12, nr. 2, pp. 45–53, 2020.

2. C. Ionescu, Utilizarea tehnicilor de Machine Learning în monitorizarea echipamentelor industriale," *Buletinul AGIR*, nr. 3, pp. 98–105, 2019.

3. D. Stan și R. Matei, Strategii moderne de mentenanță predictivă pentru sisteme mecanice," *Revista Română de Inginerie Mecanică*, vol. 8, nr. 1, pp. 21–29, 2018.

4. A. Georgescu, Analiza exploratorie a datelor în aplicații industriale," *Analele Universității Politehnica din București – Seria Automatică*, vol. 79, nr. 1, pp. 67–74, 2017.

5. L. Dumitrescu și V. Radu, Monitorizarea și diagnosticarea sistemelor de propulsie navală," *Revista Navală Română*, nr. 4, pp. 33–41, 2016.

6. E. Marinescu, Pre-procesarea datelor industriale pentru aplicații de inteligență artificială," *Studii și Cercetări de Informatică*, vol. 25, nr. 2, pp. 55–63, 2021.

7. S. Andrei, Analiza corelațiilor și selecția caracteristicilor în modele predictive," *Revista de Informatică Economică*, vol. 22, nr. 3, pp. 89–97, 2018.

8. IEEE Citation Reference," IEEE, 2009. [Online]. Disponibil: https://www.ieee.org/documents/i

9. IEEE Editorial Style Manual," IEEE, 2016. [Online]. Disponibil: https://www.ieee.org/documen